

# 佛学智能问答系统 — 产品交接文档（详细版）

交接对象：新任产品经理 文档日期：2026-06-09 代码仓库：ericjepsen9/rag-test-buddhism  
开发分支：claude/expand-buddhist-knowledge-base-BmlBm 代码规模：约 18,900 行 Python（25 个模块）+ 4 个前端页面

## 第一部分：产品概述

### 1.1 一句话定位

一个佛学知识智能问答系统（RAG）：用户用自然语言提问，系统从佛教经论讲记中检索相关内容，再用大语言模型组织成结构化的中文回答。当前知识库以《入菩萨行论》（入行论）为核心，10 品内容完整。

### 1.2 RAG 是什么（给非技术 PM）

RAG = Retrieval-Augmented Generation（检索增强生成）。不是让 AI 凭记忆瞎答，而是：1. 先检索——从我们自己的佛法讲记库里找到最相关的原文片段 2. 再生成——把这些片段交给大模型，让它“基于这些材料”组织回答

好处：回答有出处、不编造、可溯源（用户能点开“查看讲记原文”核对）。

### 1.3 三类用户与三个入口

| 用户          | 入口     | 页面文件            |
|-------------|--------|-----------------|
| 终端用户（信众/学员） | PC 聊天页 | web/chat.html   |
| 终端用户（手机）    | 移动端页   | mobile.html     |
| 运营/管理员      | 后台管理系统 | admin_page.html |

## 第二部分：功能清单（详细）

### 2.1 用户端问答功能

| 功能      | 详细说明                                                 |
|---------|------------------------------------------------------|
| 自然语言问答  | 支持定义、方法、原因、对比、辩论等各类提问                                |
| 两种回答模式  | brief（简洁） / full（详细），用户可切换                           |
| 两种用户级别  | beginner（初学者，多解释） / experienced（有基础，更精炼），影响回答深度与术语使用 |
| 流式打字机效果 | 回答逐字浮现，类 ChatGPT 体验；短回答（<20字）直接显示                    |
| 查看讲记原文  | 回答下方可展开面板，显示本次引用的原始讲记片段及其科判出处，最多 5 个来源               |
| 问题澄清    | 问题过短或模糊时（6–15 字且歧义），系统反问并给出候选选项引导                    |
| 多轮对话    | 保留最近对话历史，支持“详细说说”“展开讲”等追问                            |
| 点赞/点踩反馈 | 用户对每条回答打分（赞/踩），数据写入反馈日志用于优化                          |
| 安全干预    | 检测自杀/轻生等敏感词，返回心理援助热线 +                               |
| 相关媒体    | 佛法慰藉，不走常规问答<br>回答可附带相关图片/视频链接（基于 media.json 映射）      |

| 功能       | 详细说明                                   |
|----------|----------------------------------------|
| 关联信息     | 回答可附带跨实体关联（如人物、经典、概念之间的关系）             |
| 复制回答     | 一键复制回答文本                               |
| PWA 离线支持 | 含 manifest.json + sw.js，可"添加到主屏幕"，弱网友好 |

2.2 问答智能处理（后台自动，用户无感）

32 类问题分类（question\_classifier.py，纯规则、零延迟、零成本）：

definition（定义）、method（方法）、reason（原因）、comparison（对比）、debate（辩论）、list（列举）、overview（概述）、who（人物）、which（归属）、verse（颂词）、original\_text（原文）、howmany（数量）、reference（出处）、relation（关系）、sequence（次第）、story（公案）、chanting（念诵）、advice（建议）、practice\_detail（修行细节）、difficulty（修行困难）、experience（觉受）、precept（戒律）、application（生活应用）、emotion（情绪）、taboo（禁忌）、misconception（误解）、contemporary（现代议题）、verification（求证）、followup（追问）、recommendation（推荐）、etiquette（礼仪）、calendar（节日历法）、meta（关于系统本身）

每类问题驱动不同的搜索策略（是否跳过 FAQ、是否优先讲记内容、是否拆分检索等）。

10 类内容路由（QUESTION\_ROUTES）：

doctrine（教义）、practice（修行）、scripture（经典）、sect（宗派）、concept（概念）、history（历史）、ritual（仪轨）、basic（基础）、life（生活应用）、buddhism（通用）

系统对每个问题打分判断归属路由，不同路由用不同的检索权重和阈值。

问题改写（Query Rewrite）：扩写、同义词补充、别名召回，提升检索命中率；带 LLM 改写缓存。

2.3 检索引擎（混合检索）

| 检索方式            | 说明                                   |
|-----------------|--------------------------------------|
| 向量检索（FAISS）     | 用 BGE-M3 模型把文字转向量，按语义相似度搜索，默认权重 0.65 |
| 关键词检索（BM25）     | 基于 jieba 中文分词的关键词匹配，默认权重 0.35        |
| 混合融合            | 两路结果按路由权重融合排序                        |
| CrossEncoder 精排 | 用 BGE-reranker-v2-m3 对候选做二次精排（可开关）   |
| 分数过滤 + 去重       | 默认阈值 0.25，过滤低相关、去除重复片段               |
| 内容分层过滤          | 按内容类型（教义/修行/生活）调整权重，避免生活类内容抢占教义问答    |

2.4 回答质量保障

后处理清理（\_clean\_llm\_output，22 条规则）：自动去除科判标记（甲一、乙二、丙三…）、【讲解】等标签、回向文、原始排版残留，保证回答干净  
上下文预处理（\_build\_context）：检索片段送入 LLM 前先清洗去重  
回声检测：防止 LLM 把问题原样复述当回答  
置信度检测：低置信度时附加提示，避免误导  
自动化测试：174 个测试用例，25 个分类，当前通过率约 98%

2.5 运营端：知识库管理

| 功能       | 说明                                      |
|----------|-----------------------------------------|
| 三种导入方式   | 网页导入（URL 抓取）、文件导入（上传）、文本导入（粘贴）          |
| 支持文件格式   | .txt .md .doc .docx .pdf .html .zip（批量） |
| LLM 自动整理 | 可选，让大模型把原始文稿清洗成规范的结构化知识库格式              |
| 三步导入流程   | 抽取文本 → LLM 精炼预览 → 确认入库                  |

| 功能              | 说明                                   |
|-----------------|--------------------------------------|
| 网站爬取 (crawl_v2) | 自动发现站点链接、分页抓取、断点续传、暂停/恢复/重试、SSE 实时进度 |
| 乱码处理            | 针对 .doc 多编码自动识别 (olefile 解析)         |
| 产品/知识管理         | 创建产品、增删改查知识文件、删除产品                   |
| 索引重建            | 导入后重建<br>索引使内容生效 (耗时操作, 超时上限 3600 秒) |

FAISS

2.6 运营端：词库与配置管理

| 功能     | 说明                                                                |
|--------|-------------------------------------------------------------------|
| 同义词管理  | 系统自动学习用户用词映射 (如"业障"→"业力")，出现 ≥3 次自动审核，也支持人工添加/编辑/批量审核/批量删除        |
| 关键词管理  | 静态同义词覆盖、消歧规则、LLM 扩充关键词、从现有库提取关键词                                  |
| 参数调优   | 后台可调<br>参数、混合检索权重、Top-K、阈值、Reranker 开关等约 20 项                     |
| LLM 配置 | 对话用 / 知识整理用<br>两套独立配置，支持多供应商 (OpenAI/DeepSeek/Mini Max/自定义)，含连接测试 |
| 服务管理   | 嵌入模型、LLM 服务的启停与状态查看                                               |
| 缓存管理   | 查看/清理响应缓存、检索缓存                                                    |
| 诊断工具   | /admin/diagnose 单步调试整条问答管线                                        |
| 日志查看   | QA 日志、未命中日志、错误日志、系统日志                                             |
| 统计面板   | 系统状态、调用统计                                                         |

2.7 数据库实时查询 (新增，框架就绪待接入)

新增 sql\_bridge.py 模块，支持接入 PostgreSQL 回答数据类问题： - 自动判断"有多少人""统计""排行"等数据查询类问题 - LLM 将自然语言转 SQL (Text-to-SQL) - 安全校验 (仅允许 SELECT，禁止增删改、禁止注释、禁止危险函数) - 连接池、查询超时、行数上限保护 - 查询结果再经 LLM 转为自然语言回答 - 后台接口：配置、连接测试、读取表结构、手动查询、自然语言测试查询

第三部分：技术栈

3.1 后端

| 层      | 技术                | 说明               |
|--------|-------------------|------------------|
| Web 框架 | FastAPI + Uvicorn | Python 异步 Web 服务 |
| 数据校验   | Pydantic v2       | 请求/响应模型          |
| 限流     | slowapi           | 基于 IP 的速率限制      |
| 上传     | python-multipart  | 文件上传             |

3.2 AI / 检索

| 组件    | 技术                          | 说明                  |
|-------|-----------------------------|---------------------|
| 嵌入模型  | BAAI/bge-m3 (FlagEmbedding) | 中文向量化，支持 FP16       |
| 向量库   | FAISS (GPU 版)               | 向量索引，支持 flat / HNSW |
| 精排模型  | BAAI/bge-reranker-v2-m3     | CrossEncoder 二次精排   |
| 关键词检索 | BM25 + jieba                | 中文分词关键词匹配           |

| 组件   | 技术            | 说明                                                 |
|------|---------------|----------------------------------------------------|
| 深度学习 | PyTorch ≥ 2.0 | 模型运行时                                              |
| 大模型  | OpenAI 兼容接口   | 支持 OpenAI / DeepSeek / MiniMax / 自定义，可配 LiteLLM 格式 |

3.3 数据解析 / 抓取

| 用途      | 技术                              |
|---------|---------------------------------|
| 网页抓取    | requests + BeautifulSoup4       |
| Word 文档 | python-docx + olefile (旧版 .doc) |
| PDF     | (PDF 解析)                        |

3.4 前端


| 技术             | 说明                                             |
|----------------|------------------------------------------------|
| 原生 HTML/CSS/JS | 无框架，单文件页面，轻量                                   |
| PWA            | manifest.json + Service Worker，可安装、离线缓存        |
| SSE            | Server-Sent Events，用于爬取进度等实时推送                 |
| 兼容接口           | 提供 /v1/chat/completions OpenAI 兼容端点，可被第三方客户端接入 |

3.5 数据存储

| 数据         | 存储方式                                      |
|------------|-------------------------------------------|
| 佛法知识内容     | .txt 文本文件 (knowledge/buddhism/)           |
| 向量索引       | stores/<product>/index.faiss + docs.jsonl |
| 同义词/关键词/配置 | data/*.json 文件                            |
| 日志         | 文件日志 (QA / miss / error / system)         |
| 外部业务数据     | PostgreSQL (可选接入，sql_bridge)              |

第四部分：系统架构

4.1 问答主流程



└─ ⑩ 后处理清理 ───────── 去科判/标签/回向文 → 返回干净回答

兜底：LLM 无法生成时 → 规则抽取；仍无 → 未命中回复并记录知识缺口

## 4.2 两套数据存储的区别（高频被问）

|     | 知识库（默认）                | SQL 数据库（可选接入）       |
|-----|------------------------|---------------------|
| 存什么 | 佛法讲记、经论原文（大段非结构化文字）    | 用户、修行记录、统计数据（结构化表格） |
| 格式  | .txt 文本文件 + FAISS 向量索引 | PostgreSQL 数据表      |
| 怎么查 | 语义搜索（意思接近就能找到）         | 精确查询（条件匹配、计数、聚合）    |
| 擅长  | "菩提心是什么""如何禅修"         | "有多少人在学入行论""本月签到排行" |
| 不擅长 | 精确统计                   | 模糊语义理解              |

两者互补，系统自动判断走哪条路径，运营无需干预。

## 第五部分：API 接口总览

共 97 个端点：12 个公开 + 85 个后台管理。

### 5.1 公开端点（终端用户）

| 方法   | 路径                   | 作用                   |
|------|----------------------|----------------------|
| POST | /ask                 | 核心问答接口               |
| GET  | /chat                | PC 聊天页               |
| GET  | /mobile              | 移动端页                 |
| GET  | /health              | 健康检查                 |
| GET  | /sw.js               | Service Worker (PWA) |
| POST | /v1/chat/completions | OpenAI 兼容问答（支持流式）    |
| GET  | /v1/models           | OpenAI 兼容模型列表        |
| POST | /admin/feedback      | 用户点赞/点踩反馈            |

### 5.2 后台管理端点（按功能分组）

| 分组       | 代表端点                                                                               | 数量  |
|----------|------------------------------------------------------------------------------------|-----|
| 知识库导入    | /admin/import_knowledge、/admin/upload、/admin/fetch_url、/admin/batch_pattern_import | ~12 |
| 网站爬取 v2  | /admin/crawl_v2/discover、/start、/jobs/{id}/pause resume retry stop                 | ~11 |
| 知识文件管理   | /admin/knowledge/{product}/{filename}（增删改查）、/admin/rebuild                         | ~8  |
| 同义词管理    | /admin/synonyms/*（增删改查、审核、导入导出）                                                    | ~11 |
| 关键词管理    | /admin/keywords/*（覆盖、消歧、LLM 扩充）                                                    | ~9  |
| 参数/服务配置  | /admin/config、/admin/llm/configs、/admin/service/*                                  | ~14 |
| SQL 数据库  | /admin/sql/config test schema query ask                                            | 6   |
| 缓存/统计/日志 | /admin/cache、/admin/stats、/admin/logs/*、/admin/diagnose                            | ~10 |

## 第六部分：关键文件地图

| 文件                      | 行数   | 作用                   |
|-------------------------|------|----------------------|
| api_server.py           | 4656 | 后端服务总入口，97 个 API 端点  |
| rag_answer.py           | 2182 | 问答核心管线，所有回答逻辑        |
| search_utils.py         | 1921 | 检索逻辑（混合搜索、分块、内容类型识别） |
| import_knowledge.py     | 1075 | 知识库导入与 LLM 整理        |
| build_faiss.py          | 925  | FAISS 索引构建           |
| rag_runtime_config.py   | 907  | 全部可调参数总配置            |
| query_rewrite.py        | 745  | 问题改写/扩写              |
| keyword_extractor.py    | 622  | LLM 辅助关键词提取          |
| crawl_v2.py             | 544  | 网站爬取引擎               |
| sql_bridge.py           | 469  | PostgreSQL 实时查询（新增）  |
| clarification_engine.py | 439  | 问题澄清引导               |
| keyword_store.py        | 421  | 关键词存储管理              |
| llm_client.py           | 377  | 多供应商 LLM 连接          |
| rag_logger.py           | 281  | 日志（qa/error/event）   |
| relation_engine.py      | 247  | 跨实体关联引擎              |
| synonym_store.py        | 239  | 同义词持久化与自学习           |
| question_classifier.py  | 152  | 32 类问题分类             |
| media_router.py         | —    | 媒体关联                 |
| answer_formatter.py     | —    | 回答结构化格式化             |
| web/chat.html           | —    | 用户端聊天页               |
| admin_page.html         | —    | 后台管理页                |
| knowledge/buddhism/     | —    | 知识库内容（入行论 10 品 .txt） |
| test_quality.py         | 526  | 174 用例质量测试           |

## 第七部分：关键配置参数

全部在 rag\_runtime\_config.py，多数支持环境变量覆盖。

### 7.1 启动必备环境变量

RAG\_USE\_OPENAI=1      # 必须为 1，否则不调用 LLM，回答质量大幅下降  
ADMIN\_API\_KEY=xxx      # 后台管理密钥  
ASK\_TIMEOUT\_SEC=120      # 单次问答超时（秒）

### 7.2 核心可调参数

| 参数                         | 默认值                | 说明                     |
|----------------------------|--------------------|------------------------|
| EMBED_MODEL_NAME           | BAAI/bge-m3        | 嵌入模型                   |
| EMBED_BATCH_SIZE_BUILD     | 2                  | 建索引批次（针对显存调低，大显卡可提高加速） |
| CHUNK_SIZE / CHUNK_OVERLAP | 600 / 150          | 文本分块大小/重叠              |
| DEFAULT_TOP_K              | 8                  | 默认检索返回数                |
| HYBRID_VECTOR_WEIGHT       | /                  | 混合检索权重                 |
| KEYWORD_WEIGHT             | 0.65 / 0.35        | 混合检索权重                 |
| SCORE_THRESHOLD            | 0.25               | 相关性过滤阈值                |
| BM25_K1 / BM25_B           | 1.5 / 0.75         | BM25 调参                |
| RERANK_MODEL               | bge-reranker-v2-m3 | 精排模型                   |



| 参数                        | 默认值        | 说明              |
|---------------------------|------------|-----------------|
| LLM_MAX_TOKENS_BRIEF/FULL | 800 / 1500 | 简洁/详细回答长度上限     |
| LLM_TEMPERATURE           | 0.3        | 生成温度（越低越稳定）     |
| FAISS_INDEX_TYPE          | flat       | 索引类型（flat/hnsw） |

## 第八部分：当前状态与待办

### 8.1 已完成

【完成】入行论全 10 品知识库导入  
 【完成】问答质量自动化测试 174 用例，通过率约 98%  
 【完成】类 ChatGPT 流式打字机效果（已修复空白回答 bug）  
 【完成】"查看讲记原文"功能（已修复按钮无响应 bug）  
 【完成】用户反馈（点赞/点踩）  
 【完成】PWA 离线支持  
 【完成】32 类问题分类 + 10 类路由 + 混合检索 + 精排  
 【完成】完整后台管理（导入/爬取/词库/参数/日志/诊断）  
 【完成】PostgreSQL 实时查询框架（代码就绪）

### 8.2 待办 / 需新 PM 决策

- 【高优先】SQL 数据库接入（最高优先）—— 框架已就绪，但需要：- 安装依赖：pip install psycopg2-binary - 在 data/sql\_config.json 填入真实 PostgreSQL 连接信息 + 表结构 - 设 enabled: true 并重启 - 需提供另一个项目的数据库表结构（CREATE TABLE 语句），并为每个字段写中文描述（描述质量直接决定 Text-to-SQL 准确率）
- 多法师讲记扩展 —— 目前以索达吉堪布、生西法师两套为主，可扩充更多讲记/经论
- 硬件升级 —— 当前针对 6GB 显存优化（批次调小拖慢建索引），换大显卡可提速
- 持续质量优化 —— 根据用户点踩反馈与未命中日志补充知识、调参

### 8.3 注意事项（踩坑提醒）

【注意】知识库回答必须开启 LLM（RAG\_USE\_OPENAI=1），否则退化为原文片段堆砌  
 【注意】导入内容后必须重建索引才生效，大库耗时可达数十分钟  
 【注意】回答中若出现科判标记（甲乙丙丁）、回向文，需补充 clean\_llm\_output 清理规则  
 【注意】SQL 路径仅允许 SELECT，已做安全校验，但接入生产库建议用只读账号双重保险

## 第九部分：仓库内其他文档索引

| 文档               | 内容          |
|------------------|-------------|
| 01_当前版本完整框架结构.md | 框架结构详解      |
| 02_产品功能文档.md     | 功能清单        |
| 03_所有接口详细作用.md   | 全部 API 接口详解 |
| 04_版本更新详细说明.md   | 版本更新记录      |
| 05_替换与使用说明.md    | 部署与替换说明     |
| ARCHITECTURE.md  | 技术架构        |
| CHANGELOG.md     | 变更日志        |
| PROGRESS.md      | 进度记录        |
| docs/知识库格式规范.md  | 知识库文件格式规范   |
| 交接文档_产品经理.md     | 交接文档（精简版）   |
| 交接文档_产品经理_详细版.md | 本文档（详细版）    |

## 附：交接联系要点

代码仓库：ericjepsen9/rag-test-buddhism

开发分支：claude/expand-buddhist-knowledge-base-BmlBm

首要任务：接入 PostgreSQL（需数据库表结构 + 字段中文描述）

核心心法：这是"检索 + 生成"系统——内容质量（知识库）决定回答上限，参数调优决定下限，LLM 必须开启